REDES NEURONALES Y DEEP LEARNING · MAESTRÍA EN ESTADÍSTICA

Machine Learning clásico para el mantenimiento predictivo

Comparación de seis modelos para anticipar fallas de equipos industriales

Grupo 2: Carlos Cuenca · Wilson Sani · William Allauca · Gustavo Chaglla
Docente: Ing. Edwin Mejía, MSc · Noviembre 2026

sji9ta-carlos-cuenca.shinyapps.io/app_ML

El problema: fallas inesperadas cuestan caro

El mantenimiento suele ser periódico o correctivo. Queremos usar los datos de operación de cada equipo para **estimar su probabilidad de falla antes de que ocurra**.

Pregunta

¿Cuál de seis modelos de ML identifica mejor los equipos con riesgo de falla?

Variable objetivo

estado: Falla / Normal. Clase positiva = **Falla**.

Herramienta

Dashboard en R Shiny: carga, EDA, preparación, entrenamiento, comparación, interpretación y predicción.

Los datos: 1 000 equipos y 10 predictoras

1 000
equipos (filas)

21.5 %
con falla (215) → clases desbalanceadas

40
valores faltantes (1 % en 4 variables)

Numéricas (9)

edad · horas de operación · temperatura · vibración · presión · rpm · corriente · mantenimientos previos · calidad del aceite

Categórica (1)

tipo de equipo: Bomba 311 · Motor 297 · Compresor 242 · Turbina 150. Se excluye *id_equipo* por ser identificador.

Análisis estadístico: ¿qué distingue a los equipos que fallan?

Variable	Media Falla	Media Normal	d de Cohen	p (BH)
Vibración (mm/s)	3.93	3.13	−0.93	< 0.001
Temperatura (°C)	83.3	76.8	−0.73	< 0.001
Edad (años)	12.9	9.2	−0.68	< 0.001
Calidad del aceite	41.6	49.9	0.63	< 0.001
Horas de operación	9 070	7 642	−0.59	< 0.001
Mantenimientos previos	2.74	3.04	0.17	0.022
Tipo de equipo (χ^2)	—	—	V = 0.10	0.022
Corriente · Presión · rpm	—	—	$\lvert d \rvert < 0.1$	> 0.28

t de Welch (numéricas) y χ^2 (categórica), p ajustado por Benjamini–Hochberg.

Vibración, temperatura, edad y **desgaste del aceite** son las señales más fuertes.

La presión no difiere en promedio: su efecto es **no lineal** (riesgo en valores extremos).

Preparación de los datos

1

Imputación

mediana (numéricas) y moda (categóricas)

2

Codificación

tipo de equipo → variables dummy

3

Partición

80 % entrenamiento / 20 % prueba, estratificada (semilla 2024)

4

Escalado

estandarización solo para logística, SVM y KNN

5

Balanceo

pesos por clase: $w_k = n / (2 \cdot n_k)$

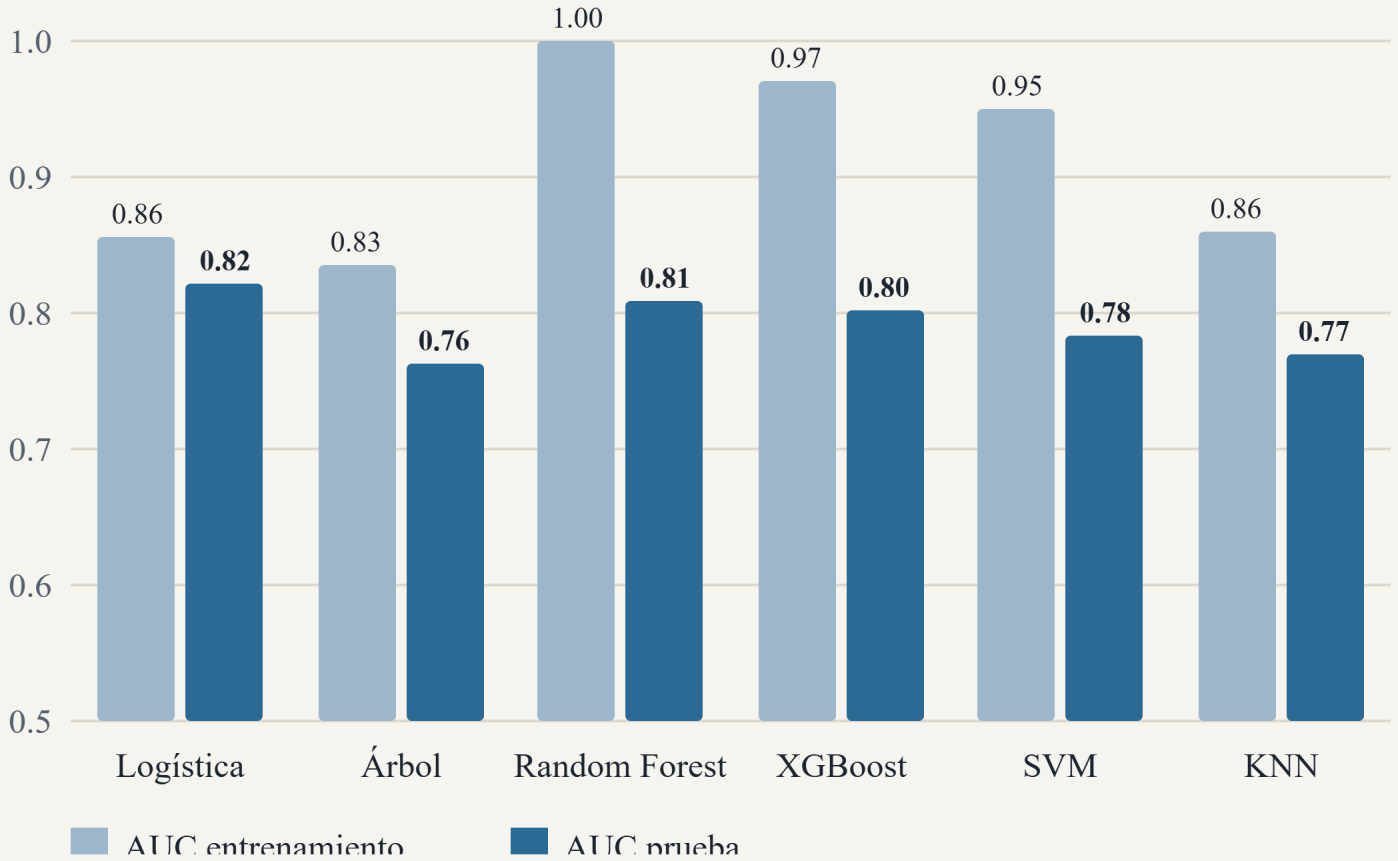
Media y desviación estándar se calculan solo con el entrenamiento, para no filtrar información del conjunto de prueba.

Seis modelos, del más simple al más flexible

Modelo	Idea	Hiperparámetros usados
Regresión logística	Lineal e interpretable (odds ratios)	—
Árbol de decisión	Reglas si-entonces	profundidad 4, cp 0.01, minsplit 20
Random Forest	Bagging de muchos árboles	300 árboles, mtry 3, nodesize 5
XGBoost	Boosting secuencial de árboles	150 rondas, profundidad 3, eta 0.05
SVM	Margen máximo con kernel	radial, C = 1, γ = 0.1
KNN	Vecinos más cercanos	k = 15

Evaluación con AUC en entrenamiento y prueba, más validación cruzada estratificada de 5 pliegues.

Resultados: memorizar no es generalizar



Random Forest llega a **AUC = 1.00** en entrenamiento, pero cae a 0.81 en prueba.

La **regresión logística** logra el mejor AUC de prueba: **0.822**.

Sobreajuste: la brecha entre entrenamiento y prueba

Modelo	Brecha AUC	Diagnóstico	AUC en CV (5)
Regresión logística	0.034	Aceptable	0.83 – 0.86
Árbol de decisión	0.073	Moderado	0.69 – 0.78
KNN	0.089	Moderado	≈ 0.79
SVM	0.167	Sobreajuste alto	0.79 – 0.83
XGBoost	0.169	Sobreajuste alto	0.78 – 0.82
Random Forest	0.191	Sobreajuste alto	0.75 – 0.82

Brecha = AUC entrenamiento − AUC prueba.

> 0.10 sobreajuste alto; 0.05–0.10 moderado; ≤ 0.05 aceptable.

Más flexibilidad = más **varianza**, no más acierto.

Réplica en Python: la conclusión se mantiene

Modelo	AUC prueba (R)	AUC prueba (Py)	CV media (Py)	Recall (Py)
Regresión logística	0.822	0.867	0.821	0.86
Random Forest	0.809	0.843	0.794	0.81
XGBoost	0.802	0.832	0.790	0.79
SVM	0.783	0.831	0.790	0.42
KNN	0.770	0.820	0.780	0.33
Árbol de decisión	0.763	0.732	0.705	0.84

scikit-learn + xgboost, mismo Excel, mismos hiperparámetros y semilla 2024.

La **logística** vuelve a ganar en AUC de prueba y en CV, con el mayor Recall (0.86).

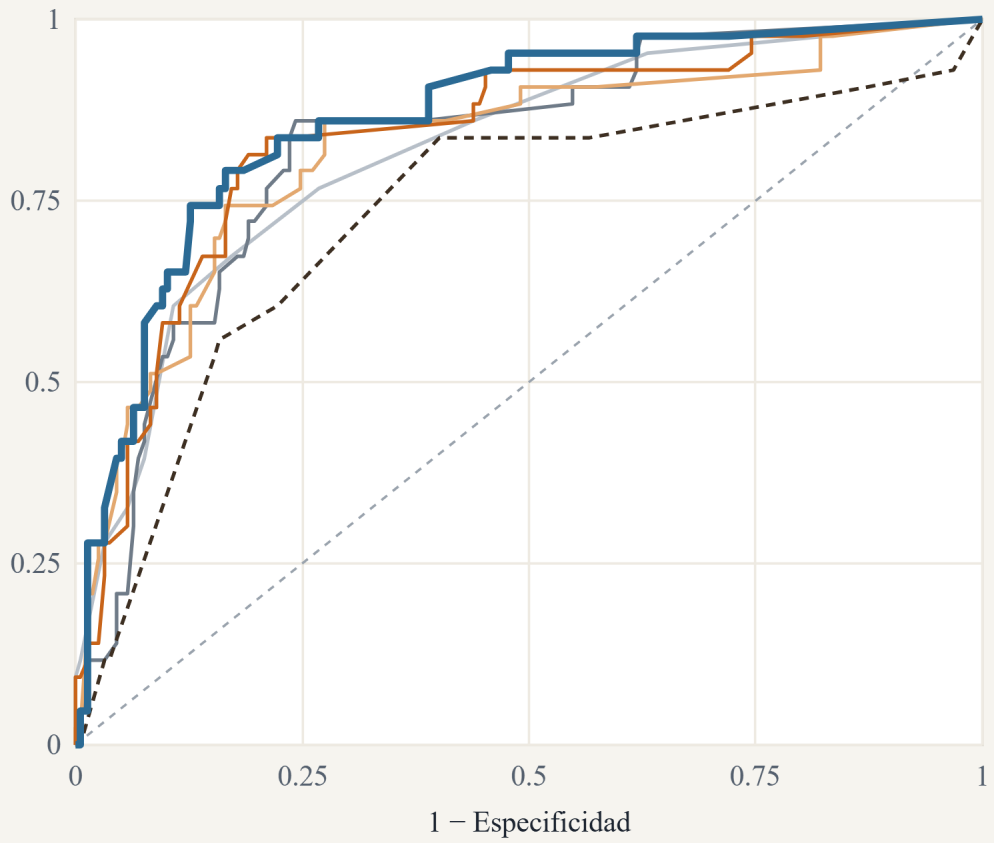
SVM y KNN tienen buen Accuracy pero detectan menos de la mitad de las fallas.

Métricas en prueba (umbral 0.5)

Modelo	Accuracy	Precision	Recall	F1	MCC	AUC
Regresión logística	0.730	0.435	0.860	0.578	0.461	0.867
Random Forest	0.795	0.515	0.814	0.631	0.524	0.843
XGBoost	0.750	0.453	0.791	0.576	0.449	0.832
SVM	0.815	0.600	0.419	0.493	0.394	0.831
KNN	0.810	0.609	0.326	0.424	0.345	0.820
Árbol de decisión	0.650	0.364	0.837	0.507	0.358	0.732

Ningún modelo gana en todo. **SVM y KNN** tienen el mejor Accuracy porque casi siempre dicen "Normal": detectan menos de la mitad de las fallas. La **logística** tiene el mayor Recall y AUC; Random Forest, el mejor F1 y MCC.

Curvas ROC y matriz de confusión



Modelo · AUC

- Regresión logística · 0.867
- Random Forest · 0.843
- XGBoost · 0.832
- SVM · 0.831
- KNN · 0.820
- Árbol de decisión · 0.732

Matriz de confusión · logística

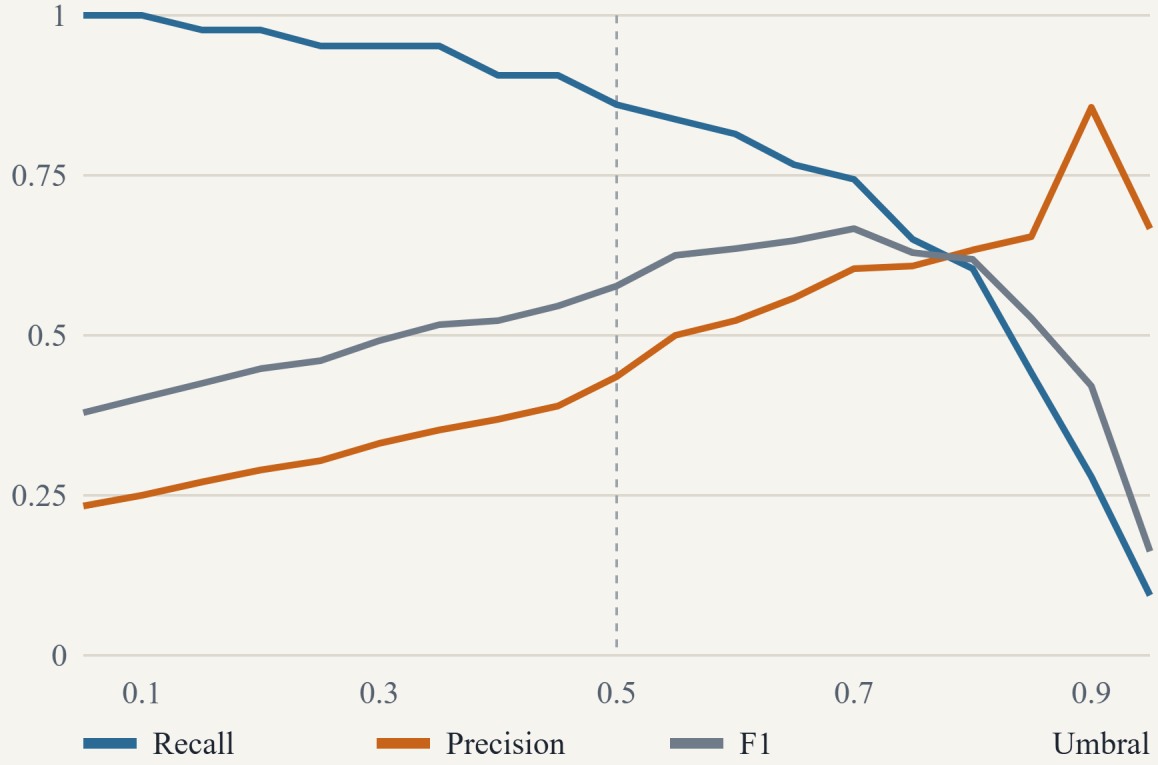
Filas = real · columnas = predicho

37 Falla detectada (VP)	**6** Falla no detectada (FN)
48 Falsa alarma (FP)	**109** Normal correcto (VN)

Detecta 37 de 43 fallas a costa de 48 inspecciones extra.

Umbral y balanceo: dos perillas para el Recall

Logística: métricas según el umbral

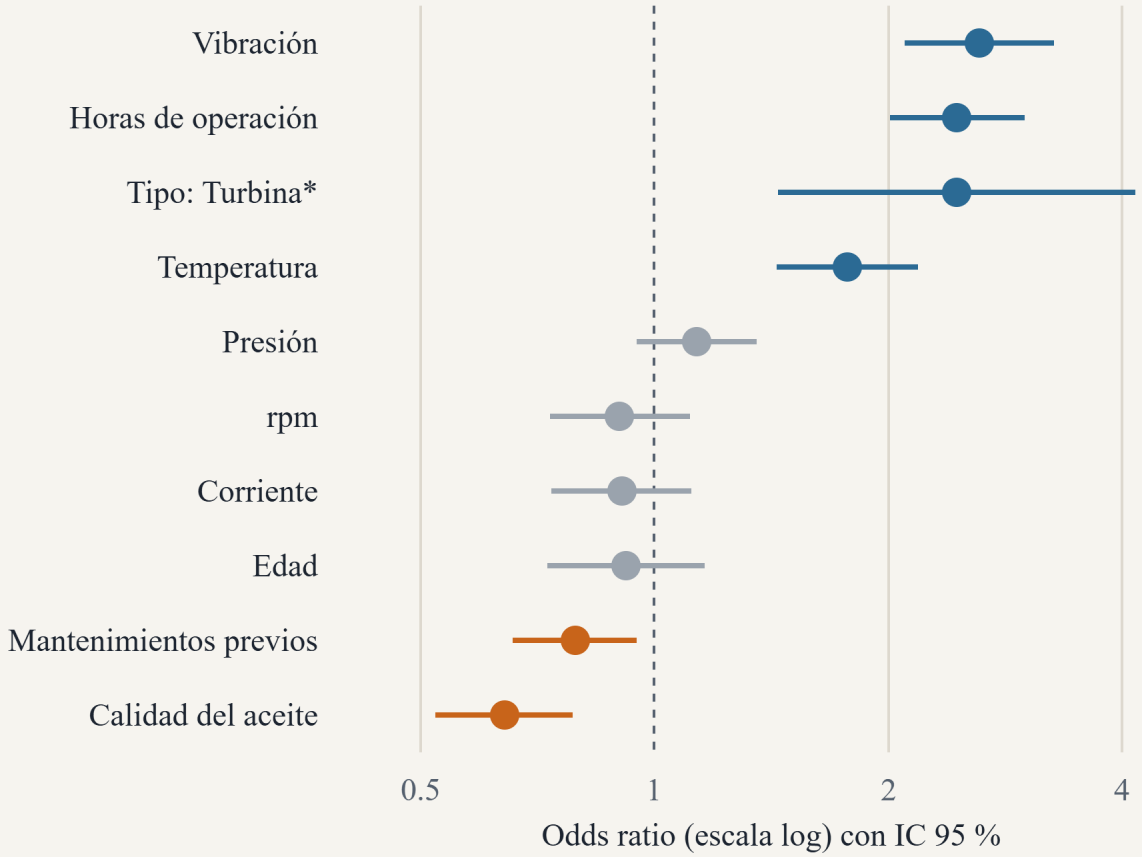


Logística con y sin pesos (umbral 0.5)

Métrica	Con pesos	Sin pesos
Accuracy	0.730	0.850
Recall	0.860	0.628
F1	0.578	0.643
Fallas detectadas	37 / 43	27 / 43

Bajar el umbral o activar los pesos **sube el Recall** y baja la Precision. Sin pesos el Accuracy mejora, pero se escapan 10 fallas más.

¿Qué variables elevan el riesgo de falla?



Aumentan el riesgo: +1 DE de vibración multiplica las odds de falla por 2.6; horas, 2.4; temperatura, 1.8. Las turbinas, 2.4 veces más que las bombas.

Protegen: calidad del aceite (0.64) y mantenimientos previos (0.79).

Vibración y horas también encabezan la importancia en Random Forest y XGBoost.

Predicción: priorizar el mantenimiento

Equipo nuevo (individual)

Turbina · 15 años · 11 000 h · 90 °C · vibración 4.5 mm/s · presión 4.0 bar · 1 mantenimiento · aceite 30

97.9 %

probabilidad de falla → **intervenir ya**

Por lotes: los 5 equipos de mayor riesgo

Equipo	Tipo	P(Falla)	Estado real
EQ-0874	Motor	0.996	Falla
EQ-0997	Bomba	0.994	Falla
EQ-0299	Bomba	0.984	Normal
EQ-0368	Turbina	0.982	Falla
EQ-0962	Turbina	0.978	Falla

La lista ordenada por probabilidad permite planificar inspecciones empezando por el mayor riesgo.

Preguntas de investigación: 1 a 5

1	**¿Qué variables se relacionan más con la falla?** Vibración (d = 0.93), temperatura, edad, calidad del aceite y horas de operación: los equipos que fallan vibran y se calientan más, son más antiguos y tienen peor aceite.	Diap. 4
2	**¿Hay diferencias significativas entre equipos con falla y normales?** Sí, en 7 de 10 variables (p ajustado BH < 0.05). No difieren corriente, presión ni rpm; la presión actúa solo en valores extremos.	Diap. 4
3	**¿Qué modelo tiene el mejor desempeño?** Regresión logística: AUC de prueba 0.822 en R y 0.867 en Python, y la validación cruzada más alta y estable.	Diap. 7 · 9
4	**¿Qué modelo identifica mejor los equipos que fallan (Recall)?** Regresión logística: Recall 0.86, detecta 37 de 43 fallas. SVM (0.42) y KNN (0.33) dejan escapar más de la mitad.	Diap. 10 · 11
5	**¿Qué diferencias hay en Accuracy, F1, AUC y MCC?** No coinciden: SVM y KNN lideran en Accuracy (0.82) por favorecer la clase Normal; Random Forest, en F1 (0.63) y MCC (0.52); la logística, en AUC.	Diap. 10

Preguntas de investigación: 6 a 10

6	**¿Qué modelo tiene mayor riesgo de sobreajuste?** Random Forest (brecha 0.19, AUC de entrenamiento = 1.00), XGBoost y SVM. A mayor complejidad, más memoriza el entrenamiento sin generalizar mejor.	Diap. 8
7	**¿Qué ocurre al cambiar el umbral y el balanceo?** Bajar el umbral o activar los pesos sube el Recall y baja la Precision. Sin pesos, el Accuracy sube a 0.85 pero el Recall cae a 0.63.	Diap. 12
8	**¿Qué variables explican mejor la probabilidad de falla?** Vibración (OR 2.6), horas (2.4), ser turbina (2.4) y temperatura (1.8) la aumentan; calidad del aceite (0.64) y mantenimientos (0.79) la reducen.	Diap. 13
9	**¿El modelo permite anticipar qué equipos requieren mantenimiento?** Sí: asigna a cada equipo una probabilidad de falla y los ordena por riesgo, para planificar inspecciones antes de la avería.	Diap. 14
10	**¿Qué modelo recomendaría implementar y por qué?** Regresión logística con umbral ajustado al costo de fallar: mejor AUC y Recall, sin sobreajuste, rápida e interpretable mediante odds ratios.	Diap. 17

Conclusión: el modelo más simple fue el mejor

Recomendación

Regresión logística: mejor AUC de prueba (0.822), menor brecha (0.034), CV más alta y estable, y el entrenamiento más rápido.

¿Por qué?

La relación entre los sensores y la falla es casi lineal en el logit. La logística la captura sin memorizar ruido.

Valor para la empresa

Odds ratios interpretables (p. ej. +1 DE de vibración multiplica por 2.6 las odds de falla) para explicar al área de mantenimiento qué variable eleva el riesgo.

Siguiente paso: ajustar el umbral para priorizar el **Recall** y regularizar los ensambles (menos profundidad, más nodesize, C menor).

PREGUNTA PARA EL DEBATE

¿Basta con elegir el modelo de mayor Accuracy, o hay que pesar el costo de los falsos negativos?

Con 21.5 % de fallas, decir siempre "Normal" ya da 78.5 % de Accuracy. Una falla no detectada cuesta mucho más que una inspección extra, por eso Recall, F1, MCC y AUC pesan más.